

# Geração de Dados Sintéticos a partir de Schemas JSON

Hugo André Coelho Cardoso José Carlos Leite Ramalho

# Motivação

#### JSON Schema

```
"$id": "https://exemplo.com/schemas/cliente",
"$schema": "https://json-schema.org/draft/2020-12/schema",
"type": "object",
"properties": {
 "nome": { "type": "string" },
 "apelido": { "type": "string" },
  "morada_envio": { "$ref": "/schemas/morada" },
  "morada_faturacao": { "$ref": "/schemas/morada" }
},
"required": ["nome", "apelido", "morada_envio", "morada_faturacao"],
"$defs": {
  "morada": {
    "$id": "/schemas/morada",
    "$schema": "https://json-schema.org/draft/2020-12/schema",
    "type": "object",
    "properties": {
     "rua": { "type": "string" },
     "cidade": { "type": "string" },
      "distrito": { "$ref": "#/$defs/distrito" }
    "required": ["rua", "cidade", "distrito"],
    "$defs": {
      "distrito": { "enum": ["Aveiro", "Beja", "... etc ..."] }
```

#### **Documentos JSON**

```
{
  "nome": "Bruno Leonel",
  "apelido": "Garrizo",
  "morada_envio": {
     "rua": "Rua de Trás da Poça, nº20",
     "cidade": "Braga",
     "distrito": "Braga"
},
  "morada_faturacao": {
     "rua": "Rua de Trás da Poça, nº20",
     "cidade": "Braga",
     "distrito": "Braga"
}
```

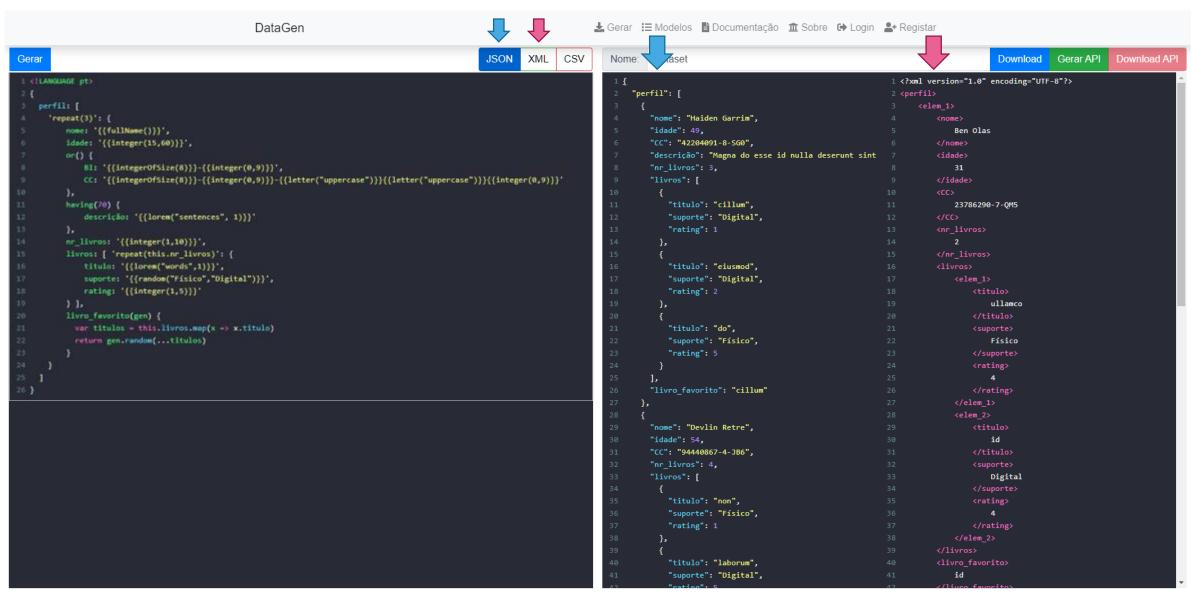
```
{
  "nome": "Tomás",
  "apelido": "Goulão",
  "morada_envio": {
     "rua": "Rua dos Álamos, nº31",
     "cidade": "Almada",
     "distrito": "Setúbal"
  },
  "morada_faturacao": {
     "rua": "Rua da Alegria, nº40",
     "cidade": "Almada",
     "distrito": "Setúbal"
  }
}
```

```
{
  "nome": "Mafalda",
  "apelido": "Costa",
  "morada_faturacao": {
    "rua": "Rua António Pedro Pares, nº 2",
    "cidade": "Lisboa",
    "distrito": "Lisboa"
}
```

```
{
  "nome": "Dayan Moisés",
  "apelido": "Rôla",
  "morada_envio": {
      "rua": "Rua Chetas Anta, nº52",
      "cidade": "Espinho",
      "distrito": "Aveiro"
  },
  "morada_faturacao": {
      "rua": 52,
      "cidade": "Espinho",
      "distrito": "Aveiro"
  }
}
```

```
{
    "nome": "Ignácio",
    "apelido": "Mengo",
    "morada_envio": null,
    "morada_faturacao": null
}
```

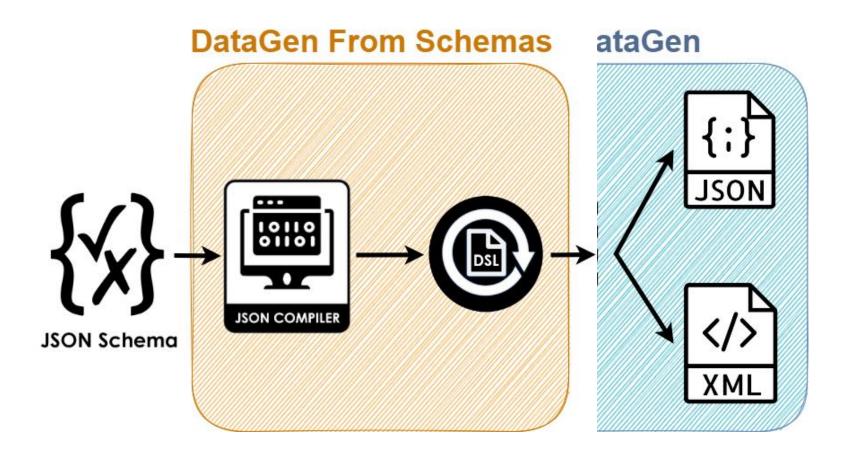
# Contextualização



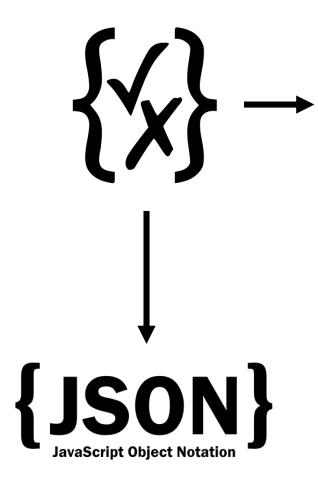
```
1 <!LANGUAGE pt>
 2 {
     perfil: [
       'repeat(3)': {
           nome: '{{fullName()}}',
           idade: '{{integer(15,60)}}',
           or() {
               BI: '{{integerOfSize(8)}}-{{integer(0,9)}}',
               CC: '{{integerOfSize(8)}}-{{integer(0,9)}}-{{letter("uppercase")}}{{letter("uppercase")}}{{integer(0,9)}}'
           },
           having(70) {
11
12
               descrição: '{{lorem("sentences", 1)}}'
           },
13
14
           nr livros: '{{integer(1,10)}}',
15
           livros: [ 'repeat(this.nr_livros)': {
               titulo: '{{lorem("words",1)}}',
17
               suporte: '{{random("Físico", "Digital")}}',
18
               rating: '{{integer(1,5)}}'
19
           } ],
           livro_favorito(gen) {
             var titulos = this.livros.map(x => x.titulo)
21
22
             return gen.random(...titulos)
23
24
25
26 }
```

```
1 <!LANGUAGE pt>
                                                                                          1 missing(50) { prop1: 1, prop2: 2 },
                                                                                                                                      1 at_least(2) {
 2 {
                                                                                          2 having(80) { prop3: 3 }
                                                                                                                                            prop1: 1,
      perfil: [
                                                                                                                                            prop2: 2,
         'repeat(3)': {
                                                                                                                                            prop3: 3
                                                                                      1 tipo: '{{random("A","B","C")}}',
             nome: '{{fullName()}}',
                                                                                                                                      5 }
                                                                                      2 if (this.tipo == "A") { A: "tipo A" }
             3 else if (this.tipo == "B") { B: "tipo B" }
                                                                                      4 else { C: "tipo C" }
             or() {
                  BI: '{{integerOfSize(8)}}-{{integer(0,9)}}',
                  CC: '{{integerOfSize(8)}}-{{integer(0,9)}}-{{letter("uppercase")}}{{letter("uppercase")}}{{integer(0,9)}}'
             },
11
             having(70) {
                  descrição: '{{lorem("sentences", 1)}}' ---- string
                                                                                                                              JS nationalities.js
12
                                                                                                     JS actors.js
                                                                                                                              JS political_parties.js
                                                                                                     JS animals.is
13
             },
                                                                                                                              JS pt_businessmen.js
                                                                                                     JS brands.js
14
             nr livros: '{{integer(1,10)}}',
                                                                                                                              JS pt_districts.js
                                                                                                     JS buzzwords.js
15
             livros: [ 'repeat(this.nr livros)': {
                                                                                                                              JS pt_entities.js
                                                                                                     JS capitals.js
                  titulo: '{{lorem("words",1)}}',
                                                                                                                              JS pt_political_parties.js
                                                                                                     JS cars.js
                                                                                                                              JS pt_politicians.js
                                                                                                     JS cities.js
17
                  suporte: '{{random("Físico", "Digital")}}',
                                                                                                                              JS pt_public_figures.js
                                                                                                     JS continents.js
                  rating: '{{integer(1,5)}}'
18
                                                                                                                              JS pt top100 celebrities.js
                                                                                                     JS countries.js
19
                                                                                                                              JS religions.js
                                                                                                     JS cultural centers.js
             livro favorito(gen) {
                                                                                                                              JS soccer_clubs.js
                                                                                                     JS gov_entities.js
                                                                                                                              JS soccer players.js
                                                                                                     JS hackers.js
21
                var titulos = this.livros.map(x => x.titulo)
                                                                                                     JS jobs.js
                                                                                                                              JS sports.js
                return gen.random(...titulos)
22
                                                                                                                              JS top100_celebrities.js
                                                                                                     JS months.js
23
                                                                                                                              JS weekdays.js
                                                                                                     JS musicians.js
24
                                                                                                                              JS writers.js
                                                                                                     JS names.is
25
26
```

## Fluxo de trabalho



### **JSON Schema**



```
Published Drafts
2020-12
Obsolete Draft 2020-12 Documents
Draft 2019-09 (formerly known as Draft 8)
Draft 7
Obsolete Draft 7 Documents
Draft 6
Draft 5
Draft 4
Draft 3
Draft 2
Draft 1
Draft 0
```

PEG.js →

```
Go to file
dmajda JSON example: Fix link to RFC 4234.
                                                  Latest commit 647d488 on 23 Sep 2016  History
As 1 contributor
150 lines (117 sloc) | 2.73 KB
  1 // JSON Grammar
   4 // Based on the grammar from RFC 7159 [1].
  6 // Note that JSON is also specified in ECMA-262 [2], ECMA-404 [3], and on the
   7 // JSON website [4] (somewhat informally). The RFC seems the most authoritative
  8 // source, which is confirmed e.g. by [5].
  10 // [1] http://tools.ietf.org/html/rfc7159
 11 // [2] http://www.ecma-international.org/publications/standards/Ecma-262.htm
  12 // [3] http://www.ecma-international.org/publications/standards/Ecma-404.htm
  13 // [4] http://json.org/
 14 // [5] https://www.tbray.org/ongoing/When/201x/2014/03/05/RFC7159-JSON
  16 // ---- 2. JSON Grammar -----
        = ws value:value ws { return value; }
  21 begin_array = ws "[" ws
                  = ws "}" ws
     end_object
      name_separator = ws ":" ws
     value_separator = ws "," ws
  28 ws "whitespace" = [ \t\n\r]*
```

## Gramática

 Restrição do valor de cada chave estritamente ao seu espaço léxico

#### boolean

uniqueltems unevaluatedItems additionalProperties ...

#### array

enum anyOf prefixItems ...

#### schema

not items propertyNames ...

••

Rotina rigorosa de validação semântica da schema

```
{
  "type": "number",
  "minimum": 50,
  "maximum": 20
}
```



Relatórios de erros



## Estrutura Intermédia

- string
  - minLength / maxLength
  - pattern
  - format
- Numeric types (integer / number)
  - multipleOf
  - minimum / exclusiveMinimum
  - maximum / exclusiveMaximum
- object
  - properties
  - patternProperties
  - additionalProperties
  - unevaluatedProperties
  - required
  - propertyNames
  - minProperties / maxProperties
- array
  - items
  - prefixItems
  - unevaluatedItems
  - contains / minContains / maxContains
  - minItems / maxItems
  - uniqueltems
- boolean
- null

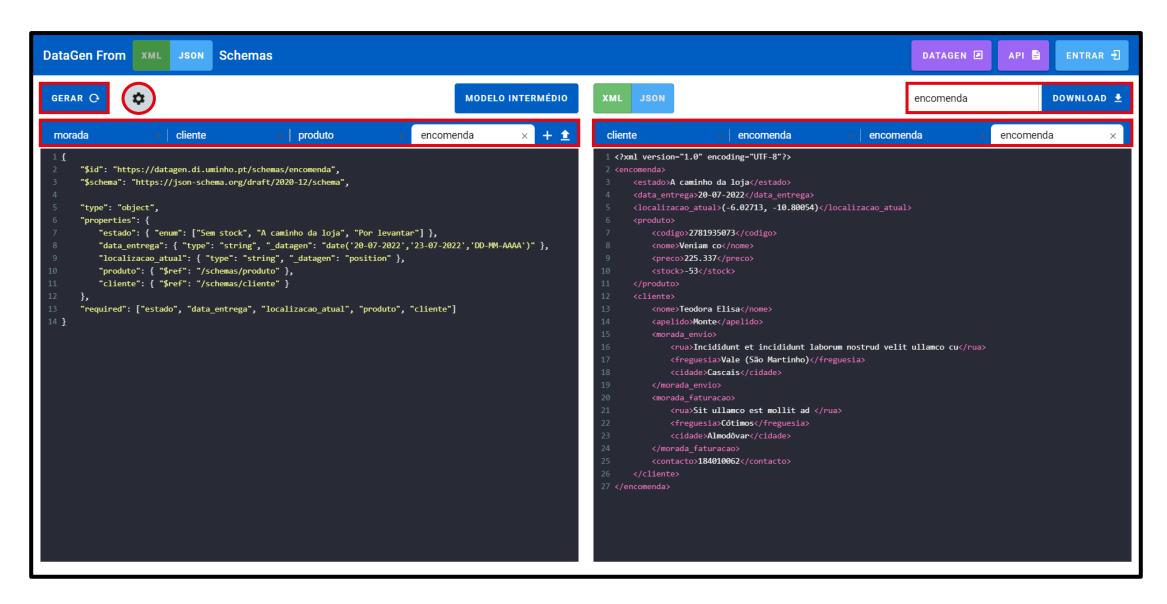
```
"oneOf": [
 { "type": "number", "multipleOf": 5 },
 { "type": "string", "minLength": 10 },
   "type": ["number", "string"],
   "multipleOf": 3,
   "maxLength": 20
```

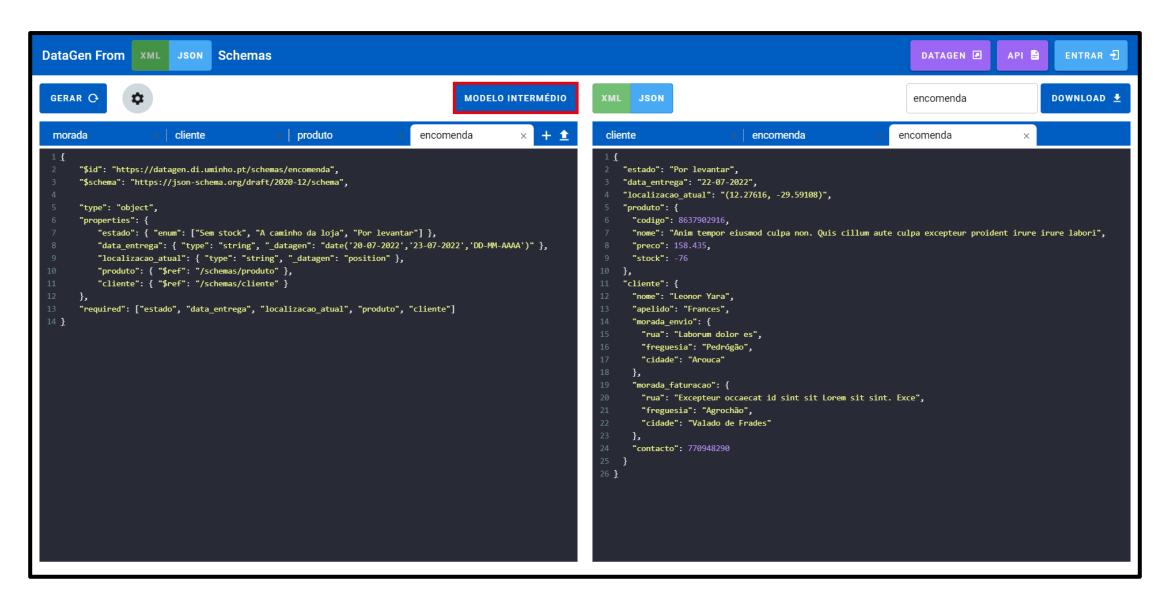
```
"oneOf": Γ
 { "type": "number", "multipleOf": 5 },
 { "type": "number", "multipleOf": 3 },
 { "type": "string", "minLength": 10 },
 { "type": "string", "maxLength": 20 }
```

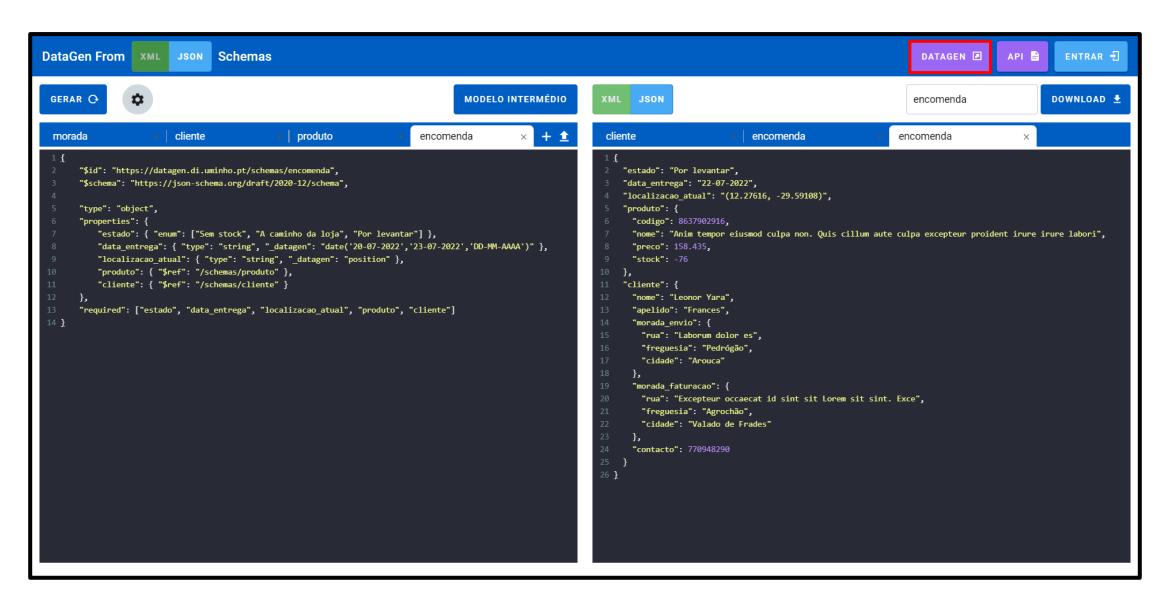
```
"number": {
  "oneOf": [
     { "multipleOf": "5" },
     { "multipleOf": "3" }
"string": {
 "oneOf": [
     { "minLength": "10" },
     { "maxLength": "20" }
```

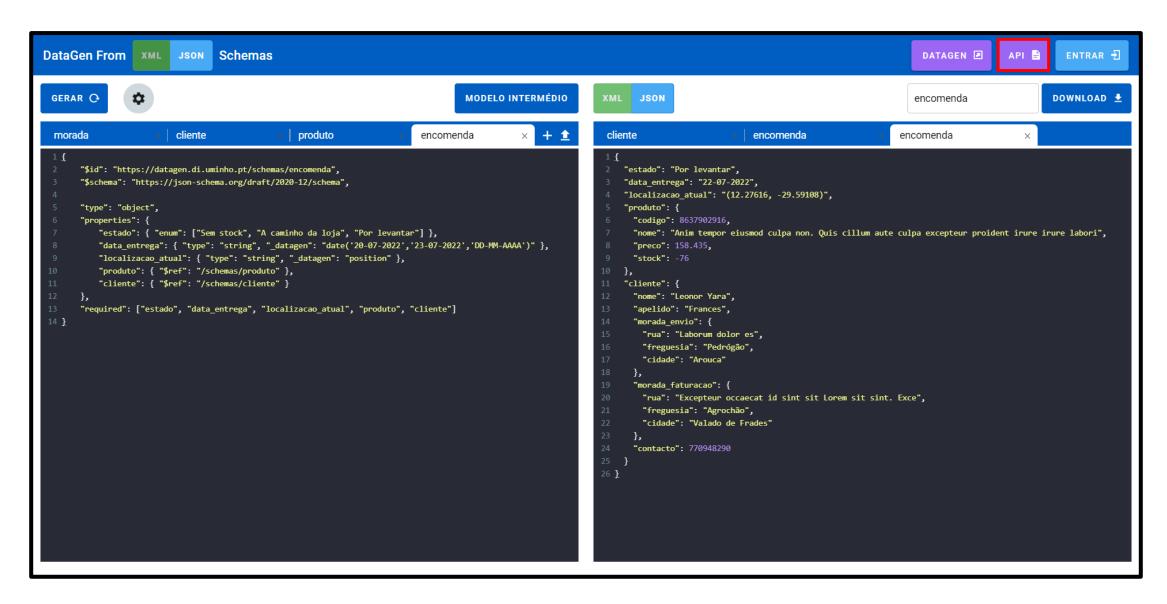
```
"type": ["string", "number"],
"maxLength": 10,
"maximum": 90,
"allOf": [
 { "type": "number", "multipleOf": 3 },
  { "type": "number", "multipleOf": 5 }
"number": {
  "maximum": 90,
  "allOf": [
   { "type": "number", "multipleOf": 3 },
```

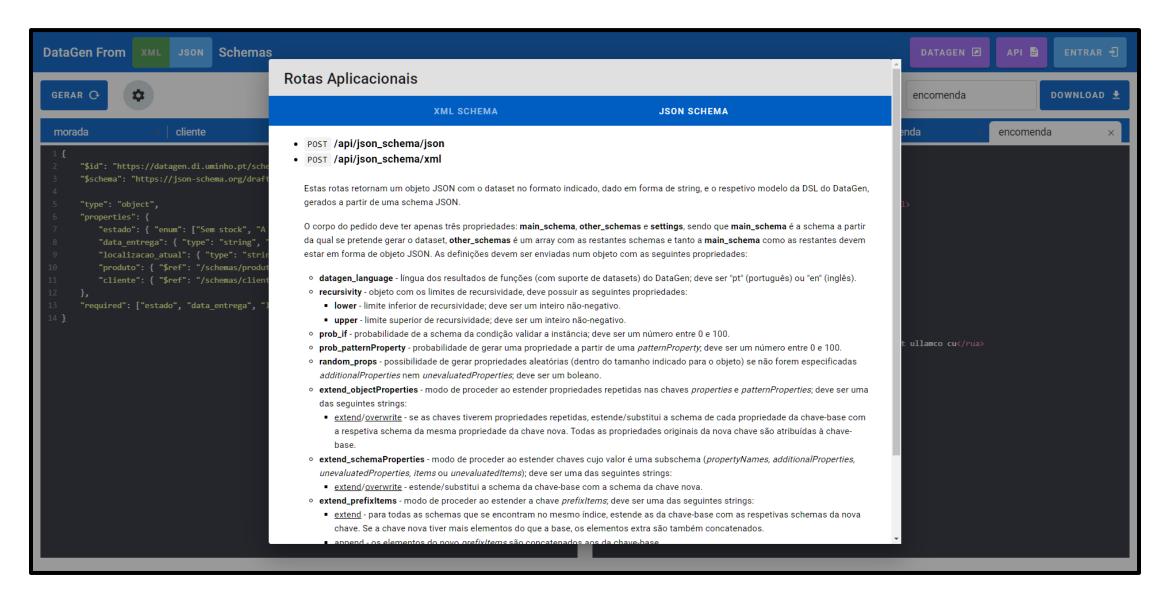
```
{ "type": "number", "multipleOf": 5 }
```











# Exemplo 1

```
+ ±
morada
                          cliente
                                                × produto
                                                                              encomenda
      "$id": "https://datagen.di.uminho.pt/schemas/encomenda",
      "$schema": "https://json-schema.org/draft/2020-12/schema",
      "type": "object",
      "properties": {
          "estado": { "enum": ["Sem stock", "A caminho da loja", "Por levantar"] },
          "data entrega": { "type": "string", " datagen": "date('20-07-2022','23-07-2022','DD-MM-AAAA')" },
          "localizacao_atual": { "type": "string", "_datagen": "position" },
          "produto": { "$ref": "/schemas/produto" },
                                                                                                               ri",
          "cliente": { "$ref": "/schemas/cliente" }
      "required": ["estado", "data_entrega", "localizacao_atual", "produto", "cliente"]
14 }
       "nome": "Leonor Yara",
       "apelido": "Frances",
       "morada envio":
                          cliente
                                                                                                   x | + ±
morada
                                                    produto
                                                                              encomenda
    "$id": "https://datagen.di.uminho.pt/schemas/cliente",
    "type": "object",
    "properties": {
      "nome": { "type": "string", "_datagen": "firstName" },
      "apelido": { "type": "string", "_datagen": "surname" },
      "contacto": { "type": "integer", "_datagen": "integerOfSize(9)" },
      "morada_envio": { "$ref": "/schemas/morada" },
      "morada faturacao": { "$ref": "/schemas/morada" }
    "required": ["nome", "apelido", "morada_envio", "morada_faturacao"]
12 }
```

```
cliente
                                                     produto
 morada
                                                                               encomenda
    "$id": "https://datagen.di.uminho.pt/schemas/produto",
    "type": "object",
    "properties": {
      "codigo": { "type": "integer", "_datagen": "integerOfSize(10)" },
      "nome": { "type": "string" },
      "preco": { "type": "number" },
      "stock": { "type": "integer" }
    "required": ["codigo", "nome", "preco", "stock"]
11 }
               <nome>Teodora Elisa</nome>
               <apelido>Monte</apelido>
 morada
                           cliente
                                                    produto
                                                                               encomenda
    "$id": "https://datagen.di.uminho.pt/schemas/morada",
    "type": "object",
    "properties": {
      "rua": { "type": "string" },
      "freguesia": { "type": "string", "_datagen": "pt_parish" },
      "cidade": { "type": "string", "_datagen": "pt_city" }
    "additionalProperties": false,
"required": ["rua", "freguesia", "cidade"]
11 }
```

# Exemplo 2

```
pessoa
pessoa
                                                                                         pessoa
                                                                                                                         pessoa
                                                                                                                                                   \times
                                                                                         1 <?xml version="1.0" encoding="UTF-8"?>
   "name": "Sidónio Vaquinhas",
   "children": [
                                                                                               <name>Kija Letra</name>
                                                                                               <children>
       "name": "Carminho Miguel Aveleiro",
                                                                                                   <elem 1>
                                                                                                       <name>Ilusinda Servo</name>
       "children": [
                                                                                                       <children>
           "name": "Yuming Florido",
                                                                                                           <elem 1>
                                                                                                               <name>Hasan Certal</name>
           "children": [
                                                                             di.umi 10
                                                                                                          </elem 1>
               "name": "Tânia Maiara Barbas",
                                                                                                               <name>Marvin Macario</name>
               "children": [
                                                                                                           </elem_2>
                   "name": "Amandla Isabella Pisoeiro"
                                                                                                       </children>
                                                                            ing",
                                                                                                   </elem 1>
                                                                                                       <name>Gurleen Trepado</name>
                   "name": "Sofya Cacheira"
                                                                                                       <children>
                                                                                                           <elem 1>
                                                                                                               <name>Milene Susana Carpalhoso</name>
                   "name": "Rafael Agostinho Beloo"
                                                                                                       </children>
                                                                                                   </elem_2>
                                                                                                   <elem_3>
                                                                                                       <name>Kaven Rogado</name>
               "name": "Rahela Albano",
                                                                                                       <children>
               "children": [
                                                                                                           <elem 1>
                                                                                                               <name>Maria Constança Serralheiro</name>
                   "name": "Luisandro José Jua"
                                                                                                           </elem_1>
                                                                                                           <elem 2>
                                                                                                               <name>Miriam Briana Barrocal
                                                                                                           </elem 2>
                                                                                                       </children>
                                                                                               </children>
           "name": "Diego Artur Murilhas",
           "children": [
```

## Exemplo 3

```
grafo
                          × grafo
  2 "nodos": [
          "id": 0.
          "nome": "Qui proident dolor qui minim fugiat. Lorem dolor fugiat nostrud deserunt. Ea eu sit minim re",
          "valor": -680
          "id": 1,
          "nome": "Ut duis laboris sunt nul",
          "valor": -76
          "id": 2,
          "nome": "Lorem ipsum do laboris excepteur Lorem adipisicing non officia. Tempor",
          "valor": -760
         "id": 3,
          "nome": "Proident mollit esse minim elit. Nisi duis elit ad ullamco eu ",
          "valor": -278
         "id": 4,
          "nome": "Ut consectetur mollit nostrud in amet mini",
          "valor": 55
         "id": 5,
          "nome": "Et voluptate velit ",
          "valor": 594
          "id": 6,
          "nome": "Duis aliquip commodo est aute a",
          "valor": -642
```

. . .

```
• • •
                                                                      grafo
                                                                                                          1 1 4
                 <origem>30</origem>
                 <peso>140.25</peso>
             </elem_1995>
                 <id>1995</id>
                 <origem>64</origem>
                 <peso>98.835</peso>
             <elem 1997>
                 <id>1996</id>
                 <origem>42</origem>
                 <peso>23.751</peso>
             </elem 1997>
             <elem_1998>
                 <id>1997</id>
                 <origem>8</origem>
                 <destino>65</destino>
                 <peso>209.256</peso>
             </elem 1998>
             <elem 1999>
                 <id>1998</id>
                 <origem>11</origem>
                 <peso>9.687</peso>
             </elem 1999>
             <elem_2000>
                 <id>1999</id>
                 <origem>14</origem>
                 <peso>193.672</peso>
             </elem_2000>
12507 </grafo>
12506 }
```



# Geração de Dados Sintéticos a partir de Schemas JSON

Hugo André Coelho Cardoso José Carlos Leite Ramalho